协同过滤算法

一、算法介绍

协同过滤简单来说是利用某兴趣相投、拥有共同经验之群体的喜好来推荐用户感兴趣的信息，个人通过合作的机制给予信息相当程度的回应（如评分）并记录下来以达到过滤的目的进而帮助别人筛选信息，回应不一定局限于特别感兴趣的，特别不感兴趣信息的纪录也相当重要。其核心思想是如果目标用户和某一用户再某些物品评分上很相似，那么目标用户对新物品的评分与该用户对新物品的评分也是类似的。

协同过滤方法可以大致分为两类：基于邻域的方法和基于模型的方法。

1. 基于邻域

在基于领域的协同过滤方法中，用户对物品的历史评分数据可以用来预测用户对新物品的评分。基于领域的方法包括两种：基于用户的推荐和基于物品的推荐。在基于用户的协同过滤方法中，目标用户对某一未接触物品的感兴趣程度，是由和用户具有相似评分模式的其他用户（近邻用户）对该物品的评分来估计的。基于物品的协同过滤方法，是根据某一用户对目标物品相似物品（近邻物品）的评分来预测用户对该目标物品的评分。

与基于邻域的方法不同的是，基于模型的方法使用评分信息来学习预测模型。主要思想是使用属性构建用户和物品之间的联系，这里的属性表示用户和物品的潜在特征，比如用户喜欢的类别和物品所属的类别。

基于邻域的协同过滤有以下优点：

- 简单性：直接且容易实现
- 可解释性：推荐结果具有直观的解释性理由
- 高效：基于模型的协同过滤系统在训练阶段需要消耗大量资源
- 稳定：一旦计算完成，后续可进行增量计算。对于具有评分的新物品或新用户加入时，仅需要计算这些新对象和系统已有对象的相似度即可。

基于邻域的协同过滤的缺点：

- 覆盖受限：由于计算两个用户间的相似度是基于他们对相同物品的评分，而且只有对相同物品进行了评分的用户才可以作为近邻。这样仅仅被近邻用户评价过的物品才会被推荐，推荐方法的覆盖将受到限制
- 对稀疏数据的敏感：基于邻域的推荐方法的准确性会因为评分数目的缺少而受到影响。由于用户通常只是对一小部分物品进行了评分，导致评分数据具有稀疏性。一方面稀疏数据导致在推荐时只使用了非常有限的近邻，另外，相似度计算也只是依赖了少量的评分，导致相似度存在偏差，影响推荐结果

2. 基于模型

用于解决推荐任务的基于模型的推荐方法有很多，包括贝叶斯聚类、潜在语义分析、支持向量机以及奇异值分解等等。

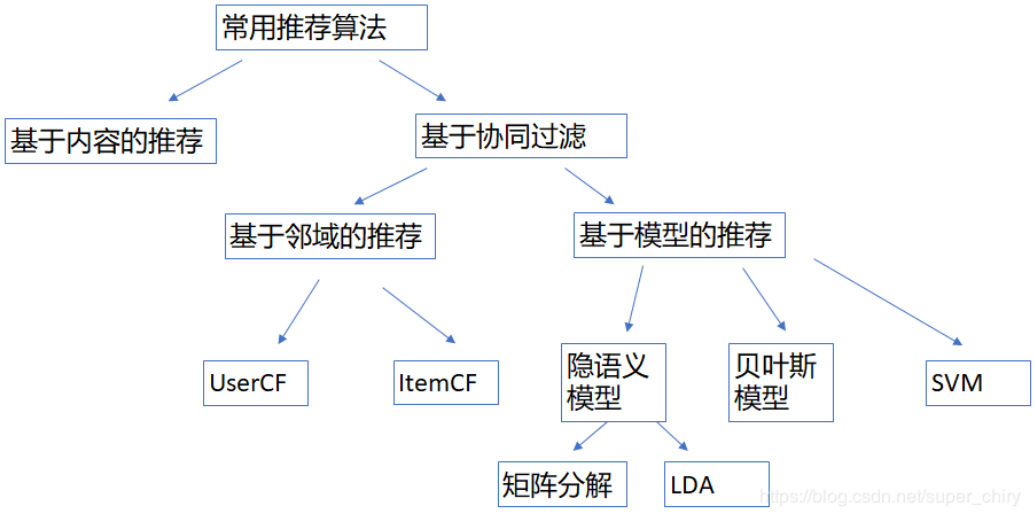

这里介绍一下对用户-物品评分矩阵进行分解的推荐模型。在这种方法中，一个 **U**x**I** 的用户-物品评分矩阵 R（矩阵秩为 n）可近似表示为 PQ^T，其中 P 是一个和基于邻域的协同过滤类似，对用户-物品评分矩阵分解，可看作在 **U**x**k** 用户因子矩阵，Q 是一个 **k**x**I** 物品因子矩阵。这样矩阵 P 的第 u 行表示用户 u 在向量空间 k 上的映射向量。同样矩阵 Q 的第 j 行表示物品 j 在向量空间 k 上的映射向量。

假设我们有一批用户数据，其中包含 m 个 User 和 n 个 Item，则我们定义 Rating 矩阵，其中的元素表示第 u 个 User 对第 i 个 Item 的评分。

在实际使用中，由于 n 和 m 的数量都十分巨大，因此 R 矩阵的规模很容易就会突破 1 亿项。这时候，传统的矩阵分解方法对于这么大的数据量已经是很难处理了。

另一方面，一个用户也不可能给所有商品评分，因此，R 矩阵注定是个稀疏矩阵。矩阵中所缺失的评分，又叫做 missing item。

针对这样的特点，我们可以假设用户和商品之间存在若干关联维度（比如用户年龄、性别、受教育程度和商品的外观、价格等），我们只需要将 R 矩阵投射到这些维度上即可。实际上我们并不需要显式的定义这些关联维度，而只需要假定它们存在即可，因此这里的关联维度即上文中的潜在向量空间 k，又被称为隐变量。k 的典型取值一般是 20 ~ 200。

用图来表示上述思想就是，用两个低维矩阵来尽可能的还原一个高维稀疏矩阵。

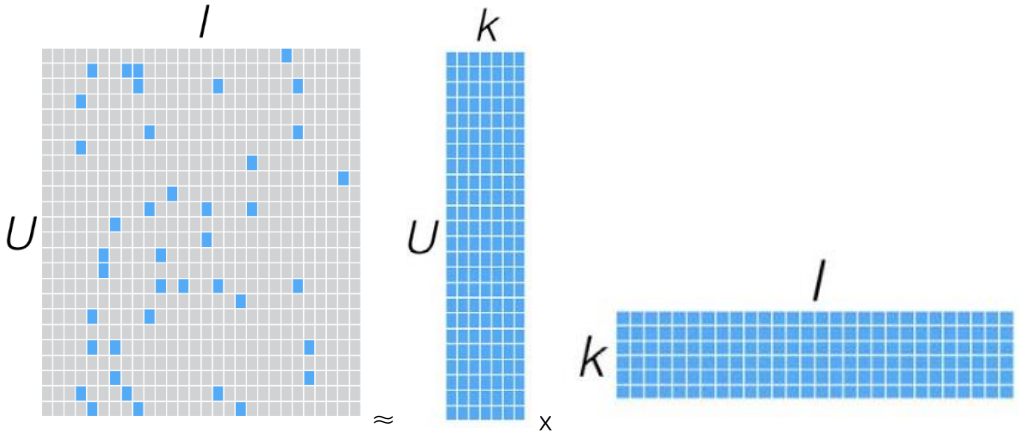

矩阵 P 和 Q 可以通过最小化以下函数来获取：

$$E(P,Q) = ||R - PQ^T||_F^2 + \lambda r(P,Q) = \sum_{u,i}(r_{ui} - p_u q_i^T)^2 + \lambda\left(\sum_u ||p_u||_2^2 + \sum_i ||q_i||_2^2\right)$$

这和基于邻域的协同过滤类似，在潜在向量空间 k 上，可计算用户间的相似度和物品间的相似度，并根据结果进行推荐。评分矩阵分解属于 User-Item CF，也叫做混合 CF。它同时考虑了 User 和 Item 两个方面。这种方法可以解决冷启动和受限覆盖的问题。

上式中第二项为 L2 正则项，保证数值计算稳定性，防止过拟合。上式最小化问题的工程解法为交替最小二乘法 ALS(Alternative Least Square)。

3. 交替最小二乘法 ALS

ALS 基本思想是对稀疏的用户-物品评分矩阵进行模型分解，评估出缺失项的值，以此来得到一个基本的训练模型。然后依照此模型可以针对新的用户和物品数据进行评估。ALS 是采用交替的最小二乘法来算出缺失项的。交替的最小二乘法是在最小二乘法的基础上发展而来的。

上述公式直接优化是很困难的，因为 P 和 Q 的二元导数不容易计算，这是可以利用类似坐标下降法的算法，先固定变量 P，对另一个变量 Q 进行优化，再反过来固定 Q，再来优化 P，持续迭代，直至收敛，即上述公式值的变化很小。因为这个迭代过程，交替优化 P 和 Q，因此又被称作交替最小二乘算法（Alternating Least Squares，ALS）。

单变量的最小值优化问题就比较简单了，可采用梯度下降法。

Spark mllib 库实现了矩阵分解的 ALS 算法，可进行直接使用。

二、推荐系统架构

基于 ALS 协同过滤的视频推荐系统架构。

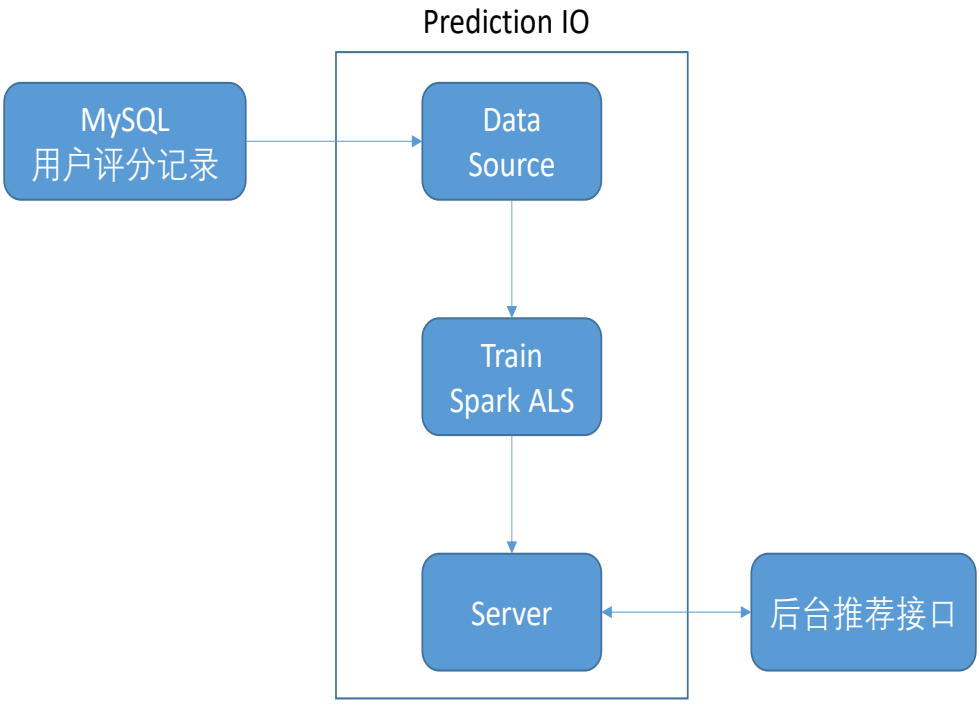

Prediction IO 是以 Spark mllib 为基础，集成了数据、模型存储及模型在线服务功能的通用机器学习框架。

Prediction IO 从系统 MySql 数据库读取用户对观看影视的评分记录，使用 Spark ALS 算法库实现评分矩阵分解，得到用户、视频的潜在特征向量，并将结果保存至 Mysql 数据库。Predition IO 带有模型在线服务功能，使用 restful 的 http 服务对后台提供推荐接口，实现基于用户历史评分记录的视频推荐和视频详情页的相似视频推荐。

三、推荐系统部署

1. 整个视频网站及推荐服务需要部署在 linux 环境下
2. 完成系统前后端部署
3. Prediction IO 安装部署：
   - 将附带的 Prediction IO 压缩包拷贝至自定义路径下，并解压缩
   - 配置系统环境变量：
     打开/etc/profile 文件，并增加下面两行
     export PIO_HOME={上一步中的 Prediction IO 文件夹绝对路径}
     PATH=$PATH:PIO_HOME/bin
     运行 pio eventserver &启动 precition io 服务，执行 pio status 检查 predition io 是否成功运行
   - 将项目 movieRecommend 压缩包上传至自定义路径下，并解压缩。
     切换至 movieRecommend 目录下，执行 run.sh，开始数据读取，模型训练以及打开在线推荐服务
     运行 check.sh，若返回数据则推荐服务正常启动